



Análise comparativa de redes neurais convolucionais na classificação de tumores pulmonares

Thiago Henrique Leite da Silva

Orientadora: Prof. Dra. Lilian Berton

Universidade Federal de São Paulo
Bacharelado em Ciência da Computação



Agradecimentos



Sumário

1. Introdução
2. Fundamentação Teórica
3. Revisão Bibliográfica
4. Proposta de Trabalho
5. Resultados
6. Considerações Finais
7. Referências



Introdução

Contextualização e Motivação


- Definição do termo câncer;
- Letalidade da doença;
- Impactos e desafios da demora no diagnóstico;
- Justificativas do trabalho.



Taxa de mortalidade por tipo de câncer em 2020

- Aproximadamente 18% dos casos de morte nesse ano foram relacionados ao câncer de pulmão.

Estimated number of deaths in 2020, worldwide, both sexes, all ages



Fonte: [Organização Mundial da Saúde](#)



Objetivo Geral

- Analisar o desempenho de redes neurais convolucionais clássicas no reconhecimento do câncer de pulmão, visando identificar a abordagem mais adequada para auxiliar profissionais de saúde no diagnóstico da doença.





Objetivos Específicos

1. Investigar e apresentar as vantagens da utilização de redes neurais convolucionais para o processamento de imagens no contexto do diagnóstico de câncer de pulmão;
2. Realizar uma análise comparativa do desempenho de diferentes arquiteturas de redes neurais convolucionais no processamento das imagens de nódulos pulmonares;
3. Aplicar heat maps para identificar as regiões mais relevantes na imagem para as redes neurais convolucionais.



Fundamentação Teórica

Aprendizado de Máquina

- Definição;
- Redes Neurais;
- Redes Neurais Convolucionais;





Processamento de Imagens Digitais

- Definição;
- Relevância desse Processo;
- *Data Augmentation*;



Gradient-weighted Class Activation Mapping (Grad-CAM)

- Técnica de visualização que permite entender quais partes de uma imagem são mais relevantes para a classificação feita por uma rede neural.




Figura 39 – Dataset Binário - Xception -
Mapa de calor para tumor benigno

Fonte: O Autor



Revisão Bibliográfica



Resumo dos Trabalhos Realizados

Referência	Metodologia	Resultados
(ALAM; ALAM; HOSSAN, 2018)	GLCM	Identificação - 97.00% Predição do Câncer - 87.00%
(HUANG et al., 2020)	ELM & DTCNN	Acurácia - 94.57%
(NISHIO et al., 2018)	SVM & XGBoost	Acurácia: SVM - 85.00% XGBoost - 89.60%
(RODRIGUES et al., 2018)	MLP, SVM, KNN	Acurácia: MLP - 95.40% SVM - 96.70% KNN - 95.30%
(NASSER; ABU-NASER, 2019)	ANN	Acurácia - 96.67%
(Poreva et. al, 2017)	DT & SVM	Acurácia: DT - 72.00% SVM - 75.00%
(TRAN et al., 2019)	2D CNN	Acurácia - 97.20% Sensibilidade - 96.00% Especificidade - 97.30%
(DOU et al., 2016)	3D CNN	Sensibilidade - 87.00% Especificidade - 99.10%
(SKOURT; HASSANI; MAJDA, 2018)	U-Net	Acurácia - 95.02%



Proposta de Trabalho



Seleção das Redes Neurais Convolucionais

- Foram selecionadas redes neurais convolucionais clássicas para a análise comparativa proposta:
 - VGG16;
 - VGG19;
 - Resnet;
 - Xception.



Base de Dados 1: *SPIE-AAPM-NCI Lung Nodule Classification*

- Inclui 22.484 imagens de tomografias computadorizadas dos pulmões de 70 pacientes;
- Possui duas classes: **tumores malignos** e **tumores benignos**.




Figura 19 – Exemplos de Imagens do Dataset SPIE-AAPM-NCI

Fonte: O Autor



Base de Dados 2: *Iraq-Oncology Teaching Hospital/National Center for Cancer Diseases*

- Inclui 1.097 imagens de tomografias computadorizadas dos pulmões de 110 pacientes diagnosticados com câncer de pulmão em diferentes estágios, bem como indivíduos saudáveis;
- Possui três classes: **tumores malignos**, **tumores benignos** e **pulmões normais** (sem tumor).




Figura 20 – Exemplos de Imagens do Dataset IQ-OTH/NCCD

Fonte: O Autor



Metodologia

1. Pré-processamento das imagens;
2. Execução dos modelos no dataset binário;
3. Aplicação da técnica de Grad-CAM para imagens do dataset binário;
4. Avaliação dos resultados e seleção das duas redes com melhor desempenho;
5. Execução dos modelos no dataset multiclasse;
6. Aplicação da técnica de Grad-CAM para imagens do dataset multiclasse;
7. Avaliação dos novos resultados;
8. Conclusões.



Resultados



Conhecendo os Termos

- **Acurácia:** porcentagem de exemplos classificados corretamente em relação ao total de exemplos;
- **Perda:** medida de quão distantes as previsões do modelo estão dos valores reais;
- **Precisão:** indica quantas das previsões positivas do modelo são realmente verdadeiras;
- **Recall:** é uma medida de sensibilidade que indica quantos dos exemplos positivos o modelo conseguiu encontrar;
- **F1 Score:** é uma métrica que combina a precisão e o *recall* em uma única medida, útil quando queremos uma avaliação geral do desempenho do modelo;
- **Matriz de confusão:** A matriz de confusão é uma tabela que mostra a contagem de exemplos classificados corretamente e incorretamente pelo modelo para cada classe;
- **Parâmetros:** são os valores que a rede aprende durante o treinamento;

Dataset Binário: Pré-processamento das Imagens




Figura 23 – Processo de *data augmentation*

Fonte: O Autor



Dataset Binário: Parâmetros da Execução

- 70 épocas;
- Função de perda: *binary crossentropy*;
- Função de ativação: *sigmoid* com uma unidade;
- Otimizador: Adam com taxa de aprendizado de $10e-5$.



Dataset Binário: Execução dos Modelos

Tabela 4 – Dataset Binário - Resumo dos resultados do modelo VGG16

Acurácia	0.96147
Perda	0.11648
Precisão	0.92701
F1 Score	0.96196
Recall	1.0

Tabela 5 – Dataset Binário - Resumo dos resultados do modelo VGG19

Acurácia	0.99371
Perda	0.02032
Precisão	0.99569
F1 Score	0.99343
Recall	0.99143

Tabela 6 – Dataset Binário - Resumo dos resultados do modelo Resnet

Acurácia	0.99109
Perda	0.02350
Precisão	0.98211
F1 Score	0.99106
Recall	1.0

Tabela 7 – Dataset Binário - Resumo dos resultados do modelo Xception

Acurácia	0.99868
Perda	0.00429
Precisão	0.99786
F1 Score	0.99856
Recall	0.99946




Figura 25 – Dataset Binário - Resultados VGG16

Fonte: O Autor




Figura 27 – Dataset Binário - Resultados VGG19

Fonte: O Autor

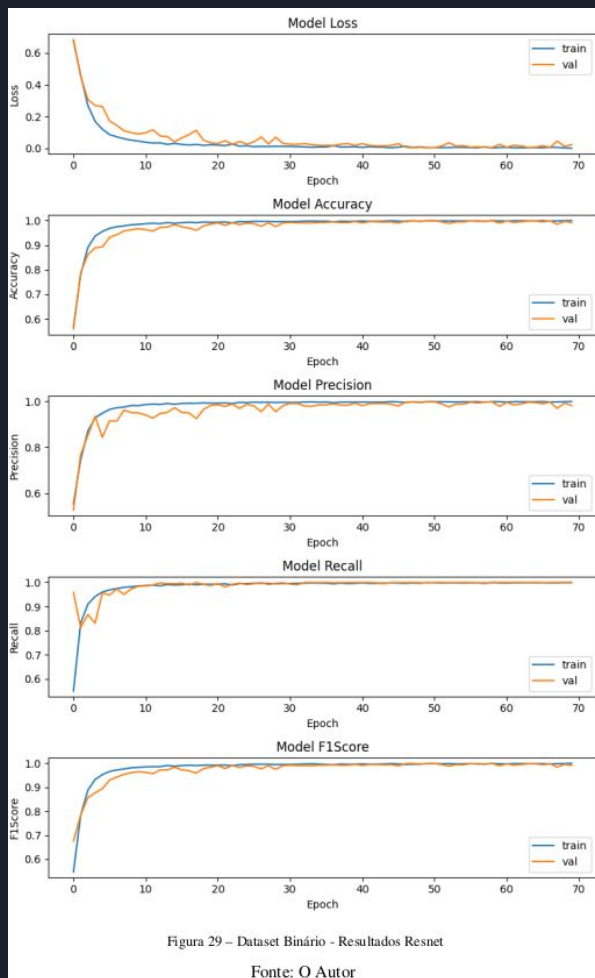


Figura 29 – Dataset Binário - Resultados Resnet

Fonte: O Autor

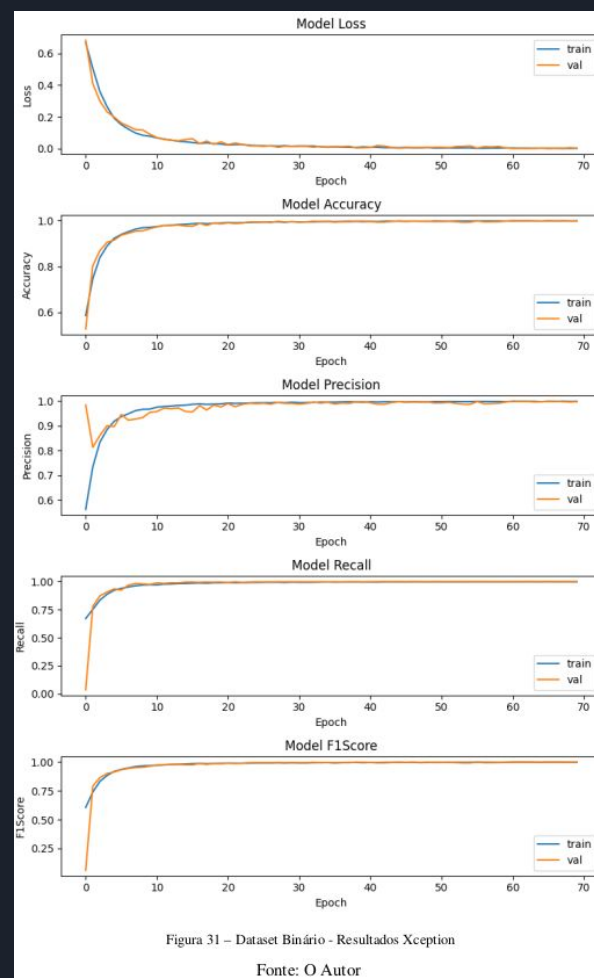


Figura 31 – Dataset Binário - Resultados Xception

Fonte: O Autor

Dataset Binário: Técnica de Grad-CAM




Figura 32 – Dataset Binário - VGG16 -
Mapa de calor para tumor benigno

Fonte: O Autor




Figura 34 – Dataset Binário - VGG19 -
Mapa de calor para tumor benigno

Fonte: O Autor




Figura 36 – Dataset Binário - Resnet -
Mapa de calor para tumor benigno

Fonte: O Autor




Figura 38 – Dataset Binário - Xception -
Mapa de calor para tumor benigno

Fonte: O Autor

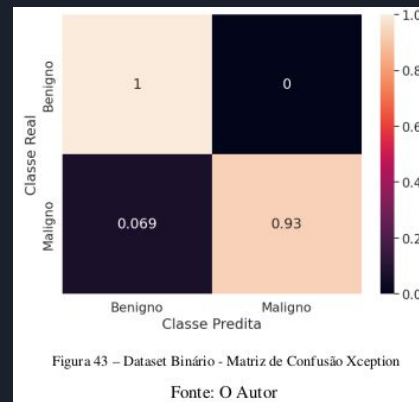

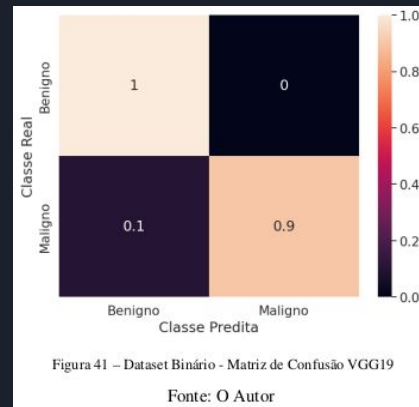



Dataset Binário: Parâmetros das Redes

Tabela 8 – Quantidade de parâmetros dos modelos treinados

Modelo	Parâmetros
VGG16	14.953.313
VGG19	20.263.009
Xception	21.542.473
Resnet	24.268.705

Dataset Binário: Matriz de Confusão





Dataset Binário: Avaliação dos Resultados

- Todos os modelos selecionados apresentaram desempenho bastante satisfatório para o problema de classificação binária;
- Pode-se observar que os modelos com maior quantidade de parâmetros, como a Resnet e Xception, tiveram uma vantagem em relação aos modelos baseados na arquitetura VGG16 e VGG19;
- Os modelos que obtiveram os melhores resultados foram aqueles que possuíam uma maior quantidade de parâmetros e que classificavam como parte mais relevante da imagem toda a abrangência dos pulmões na aplicação da técnica de Grad-CAM.



Dataset Multiclasse: Parâmetros da Execução

- 35 épocas;
- Função de perda: *sparse categorical crossentropy*;
- Função de ativação: *softmax* com três unidade;
- Otimizador: Adam com taxa de aprendizado de $10e-5$.




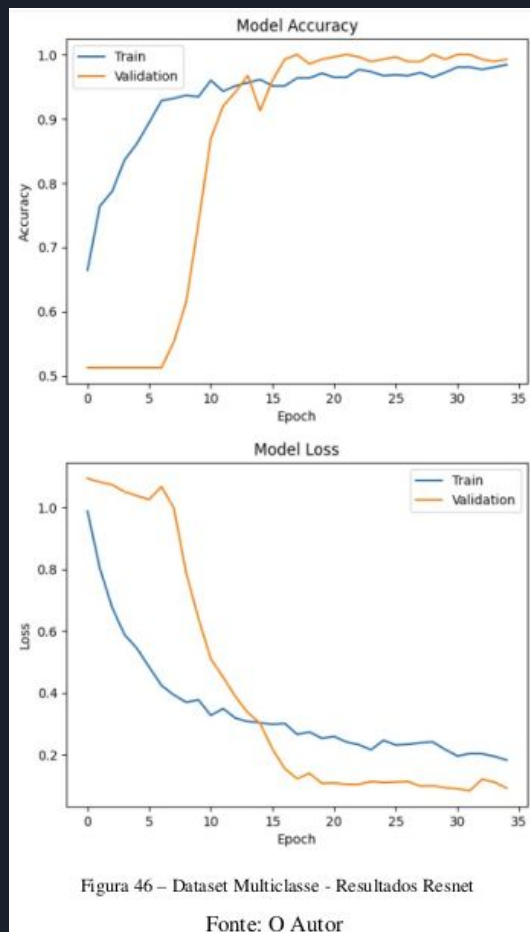
Dataset Multiclasse: Execução dos Modelos

Tabela 9 – Dataset Multiclasse - Resumo dos resultados do modelo Resnet

Acurácia	0.9927
Perda	0.0920
Precisão	0.9800
F1 Score	0.9900
Recall	0.9900

Tabela 10 – Dataset Multiclasse - Resumo dos resultados do modelo Xception

Acurácia	0.9927
Perda	0.0688
Precisão	0.9900
F1 Score	0.9900
Recall	0.9900



Dataset Multiclasse: Técnica de Grad-CAM



Figura 49 – Dataset Multiclasse - Resnet - Mapa de calor para tumor benigno

Fonte: O Autor




Figura 50 – Dataset Multiclasse - Resnet - Mapa de calor para tumor maligno

Fonte: O Autor



Figura 51 – Dataset Multiclasse - Resnet - Mapa de calor para pulmões sem tumor

Fonte: O Autor



Figura 52 – Dataset Multiclasse - Xception - Mapa de calor para tumor benigno

Fonte: O Autor



Figura 53 – Dataset Multiclasse - Xception - Mapa de calor para tumor maligno

Fonte: O Autor




Figura 54 – Dataset Multiclasse - Xception - Mapa de calor para pulmões sem tumor

Fonte: O Autor

Dataset Multiclasse: Matriz de Confusão



Figura 55 – Dataset Multiclasse - Matriz de Confusão Resnet

Fonte: O Autor

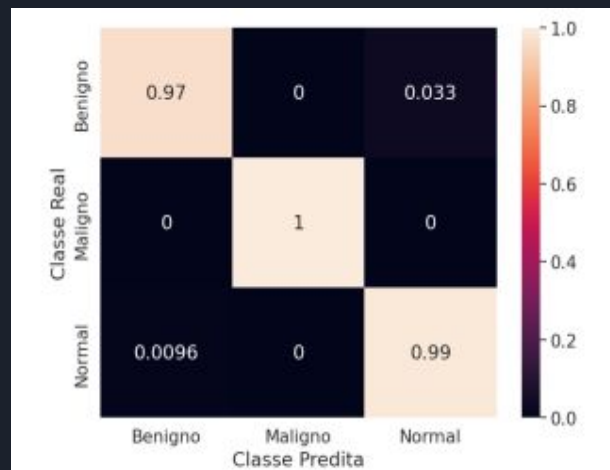


Figura 56 – Dataset Multiclasse - Matriz de Confusão Xception

Fonte: O Autor



Dataset Multiclasse: Avaliação dos Resultados

- Em resumo, os modelos Resnet e Xception mostraram um desempenho excelente no conjunto de dados multiclasse IQ-OTH/NCCD, com altas taxas de acurácia e precisão. Os resultados destacam a capacidade dos modelos em classificar corretamente os pulmões com tumores malignos, enquanto alguns erros foram observados na distinção entre tumores benignos e pulmões normais.



Considerações Finais



Conclusões

- As redes neurais convolucionais têm se mostrado altamente eficientes na classificação de tumores pulmonares;
- Redes com um maior número de parâmetros, capazes de abranger uma área mais ampla do pulmão para identificar as regiões mais relevantes da imagem, apresentam resultados superiores na classificação;
- Os bons resultados obtidos no conjunto de dados binários se estendem também para a base de dados multiclasse, demonstrando que as redes são capazes de lidar com diferentes abordagens com sucesso.




Trabalhos Futuros

- Implementar e validar clinicamente os modelos selecionados, como as redes Resnet e Xception, em colaboração com profissionais de saúde;
- Realizar testes adicionais em conjuntos de dados mais amplos e diversificados, considerando diferentes tipos de câncer de pulmão e variações nas condições de aquisição das imagens;
- Realizar validação clínica dos modelos propostos, coletando dados clínicos reais e avaliando o desempenho em condições do mundo real.



Referências



[1] ALAM, J.; ALAM, S.; HOSSAN, A. Multi-stage lung cancer detection and prediction using multi-class svm classifie. In: IEEE. 2018 International conference on computer, communication, chemical, material and electronic engineering (IC4ME2). [S.l.], 2018. p. 1–4.

[2] ALYASRIY HAMDALLA; AL-HUSEINY, M. The IQ-OTH/NCCD lung cancer dataset. 2020. Website. Disponível em: <<https://www.kaggle.com/datasets/hamdallak/the-iqothnccd-lung-cancer-dataset?sort=votes>>. Acesso em: 20.12.2022.

[3] CAMPBELL, M.; JR, A. J. H.; HSU, F.-h. Deep blue. Artificial intelligence, Elsevier, v. 134, n. 1-2, p. 57–83, 2002.


[4] CARVALHO, A. C. P. d. L. et al. Inteligência artificial: riscos, benefícios e uso responsável. Estudos Avançados, SciELO Brasil, v. 35, p. 21–36, 2021.


[5] CDC. Cancer Statistics At a Glance. 2021. Website. Disponível em: <<https://gis.cdc.gov/Cancer-/USCS/AtAGlance/>>. Acesso em: 06.6.2022.

[6] CHATURVEDI, P. et al. Prediction and classification of lung cancer using machine learning techniques. IOP Conference Series: Materials Science and Engineering, IOP Publishing, v. 1099, n. 1, p. 012059, mar 2021. Disponível em: <<https://doi.org/10.1088/1757-899x/1099/1/012059>>.

[7] CHOLLET, F. Xception: Deep learning with depthwise separable convolutions. In: Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2017. p. 1251–1258.

[8] DOU, Q. et al. Multilevel contextual 3-d cnns for false positive reduction in pulmonary nodule detection. IEEE Transactions on Biomedical Engineering, IEEE, v. 64, n. 7, p. 1558–1567, 2016.

- 
- [9] DUMOULIN, V.; VISIN, F. A guide to convolution arithmetic for deep learning. ArXiv, abs/1603.07285, 2016.
- [10] FAWCETT, T. An introduction to roc analysis. Pattern recognition letters, Elsevier, v. 27, n. 8, p. 861–874, 2006.
- [11] GONZALEZ, R. C.; WOODS, R. E. Digital image processing. Upper Saddle River, N.J.: Prentice Hall, 2008. ISBN 9780131687288 013168728X 9780135052679 013505267X. Disponível em:
<<http://www.amazon.com/Digital-Image-Processing-3rd-Edition/dp/013168728X>>.
- [12] GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. [S.l.]: MIT Press, 2016.
<http://www.deeplearningbook.org>.
- [13] GURNEY, K. An Introduction to Neural Networks. London: CRC press, 1997. 234 p. ISBN 9781315273570.
- [14] HANSON, R.; STUTZ, J.; CHEESEMAN, P. Bayesian classification theory. [S.l.], 1991.
- [15] HAYKIN, S. Neural Networks and Learning Machines. Pearson Education, 2011. ISBN 9780133002553. Disponível em:
<<https://books.google.com.br/books?id=faouAAAAQBAJ>>.
- [16] HE, K. et al. Deep residual learning for image recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2016. p. 770–778.
- [17] HUANG, X. et al. Deep transfer convolutional neural network and extreme learning machine for lung nodule diagnosis on ct images. Knowledge-Based Systems, Elsevier, v. 204, p. 106230, 2020.

- 
- [18] IBGE. Ministério do Planejamento, Orçamento e Gestão. Instituto Brasileiro de Geografia e Estatística - Rio de Janeiro. Pesquisa Nacional por Amostra de Domicílios. 2008. Website. Disponível em: <<https://www.ibge.gov.br/>>. Acesso em: 07.6.2022.
- [19] INCA. O que é câncer? 2020. Website. Disponível em: <<https://www.inca.gov.br/o-que-e-cancer>>. Acesso em: 15.5.2022.
- [20] INCA. Como surge o câncer? 2021. Website. Disponível em: <<https://www.inca.gov.br/como-surge-o-cancer>>. Acesso em: 08.6.2022.
- [21] LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. nature, Nature Publishing Group UK London, v. 521, n. 7553, p. 436–444, 2015.
- [22] LECUN, Y.; KAVUKCUOGLU, K.; FARABET, C. Convolutional networks and applications in vision. In: IEEE. Proceedings of 2010 IEEE international symposium on circuits and systems. [S.l.], 2010. p. 253–256.
- [23] MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. Sistemas inteligentes-Fundamentos e aplicações, Manole, v. 1, n. 1, p. 32, 2003.
- [24] NASSER, I. M.; ABU-NASER, S. S. Lung cancer detection using artificial neural network. International Journal of Engineering and Information Systems (IJEAIS), v. 3, n. 3, p. 17–23, 2019.
- [25] NISHIO, M. et al. Computer-aided diagnosis of lung nodule using gradient tree boosting and bayesian optimization. PLOS ONE, Public Library of Science, v. 13, n. 4, p. 1–13, 04 2018. Disponível em: <<https://doi.org/10.1371/journal.pone.0195875>>.



Obrigado pela atenção!